Tech Challenge Fase 2 – Predição de Bons e Maus Pagadores

- Objetivo: Reduzir inadimplência em cartões com modelagem preditiva
- Grupo 47
- Eduardo Henrique Neves
- Elizangela Moreira de Sousa

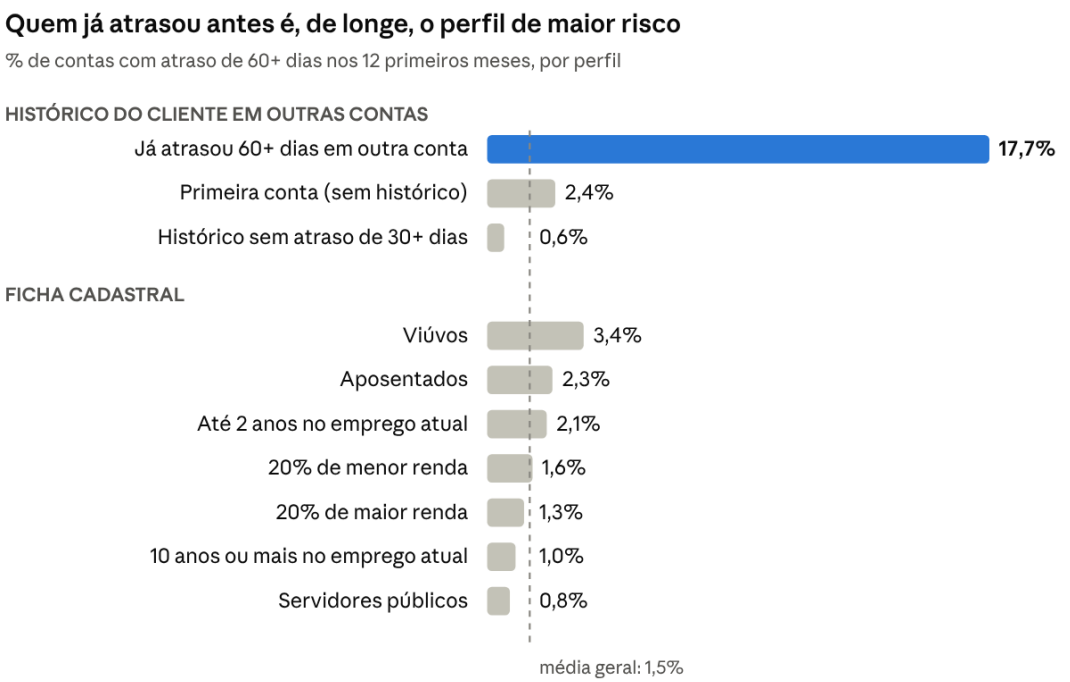
Problema e Dados

- 438.557 pedidos cadastrais
- 36.457 contas com histórico (~9.700 pessoas)
- 24.566 contas válidas para modelagem
- 370 maus pagadores (1,5%)

Mau pagador: atraso ≥60 dias nos 12 primeiros meses.

Principais Descobertas dos Dados

- Histórico prévio é o principal indicador de risco.
- Renda, idade e escolaridade têm baixo poder preditivo.

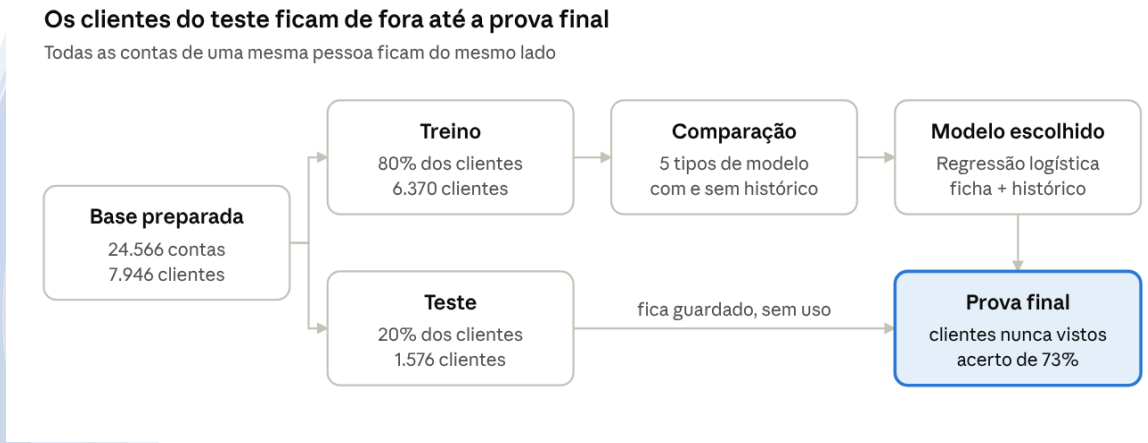


Preparação e Engenharia de Dados

- **Mesma pessoa em várias contas: ficha idêntica nos 17 campos = 1 cliente**
- Conversão de idade e tempo de emprego para anos
- Tratamento de inconsistências e de 47 IDs duplicados
- Variáveis derivadas: renda per capita, estabilidade e histórico do cliente

Construção do Modelo

- Treino: 80% dos clientes
- Teste: 20% clientes inéditos
- Modelo escolhido: Regressão Logística



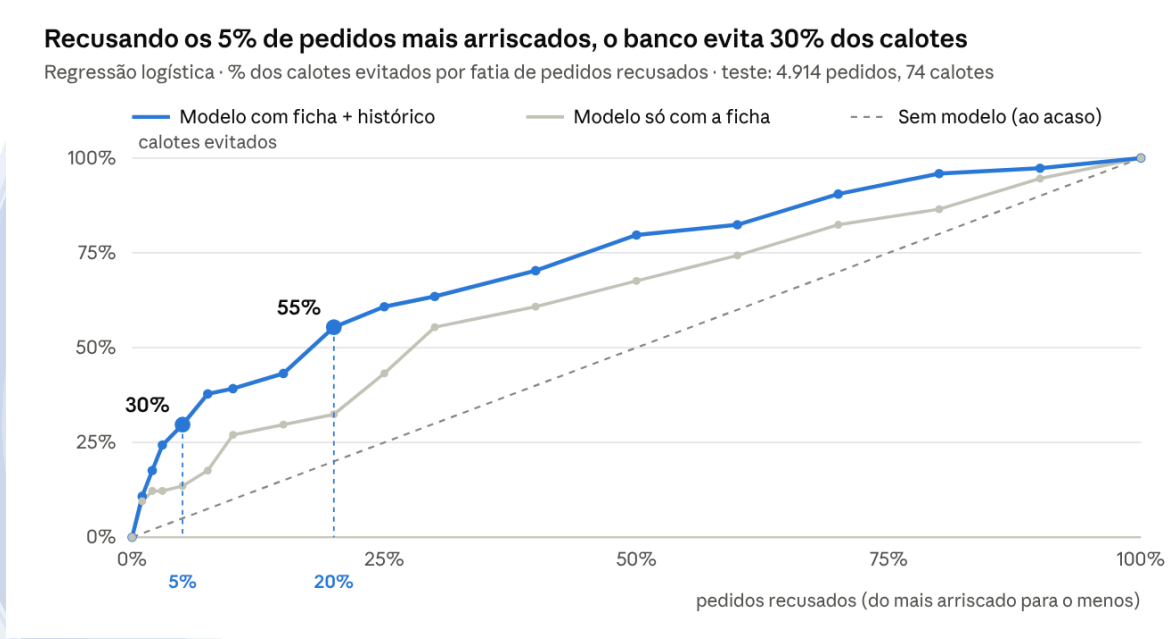
Fatores Mais Importantes

- 5 dos 6 fatores principais vêm do histórico do cliente.
- Informações cadastrais contribuem pouco para a decisão.
- Regressão logística: cada recusa pode ser explicada pelos pesos dos fatores.



Resultados de Negócio

- Recusar 5% mais arriscados evita ~30% dos calotes.
- Recusar 20% evita ~55%.
- Acerto de 73% ao comparar um bom e um mau pagador (sorteio: 50%).
- Custo do corte de 5%: cerca de 10 bons clientes recusados por calote evitado.



Recomendações e Conclusão

- Aprovação automática para a metade mais segura
- Limite inicial menor na faixa intermediária
- Análise manual dos 5% mais arriscados
- Buscar dados externos para novos clientes
- Remover gênero, idade e estado civil do modelo

- Conclusão: o valor está nos dados históricos, mais do que no algoritmo.