Relatório — Tech Challenge Fase 2: Predição de Bons e Maus Pagadores

Resumo executivo

Construímos um modelo que coloca os pedidos de cartão de crédito em ordem de risco. **Recusando apenas os 5% de pedidos mais arriscados, o banco evitaria cerca de 30% dos calotes.** Nos testes, comparando um mau e um bom pagador ao acaso, o modelo deu nota de risco maior ao mau em 73% das vezes. Um sorteio acertaria 50%; um modelo perfeito, 100%. O modelo escolhido é uma regressão logística, que permite explicar cada recusa pelos fatores que a motivaram.

O principal aprendizado não veio do algoritmo, e sim dos dados:

- **O que mais prevê um atraso é o histórico do próprio cliente.** Quem já atrasou mais de 60 dias em outra conta volta a atrasar em quase 1 a cada 6 casos. Quem tem histórico limpo atrasa em menos de 1 a cada 100.
- **A ficha cadastral, sozinha, prevê pouco.** Renda, idade, escolaridade e profissão quase não separam bons de maus pagadores nesta base.
- **O modelo apoia a decisão, mas não decide sozinho.** Ele separa bem os extremos (os clientes muito seguros e os muito arriscados). Na faixa do meio, a separação é fraca.

Recomendação: usar o modelo para aprovar automaticamente a metade mais segura dos pedidos e enviar os 5% mais arriscados para análise manual. O ponto de corte final deve ser decidido pela área de crédito, com base no prejuízo médio de um calote e no lucro médio de um bom cliente.

Identificação

Campo	Valor
Turma	12DTAT
Grupo	Grupo 47
Integrantes	Eduardo Henrique Neves — RM 377826 · Elizangela Moreira de Souza — RM 377829
Repositório	https://github.com/eddgrung-debug/tech_challenge_fiap.git
Vídeo	https://youtu.be/lJSZhKOQ2FM
Apresentação	https://github.com/eddgrung-debug/tech_challenge_fiap/blob/64390d4ea982d03ed5a3a6242b17462d44f88750/docs/Apresentacao_TechChallenge_Fase2.pdf

O problema de negócio

Cada cartão aprovado para quem não paga vira prejuízo; cada bom cliente recusado vira receita perdida. Hoje a decisão depende de análise caso a caso e de regras fixas, como faixas de renda. Isso é lento e não aproveita o que os dados históricos mostram.

O projeto respondeu a três perguntas:

1. A ficha cadastral do solicitante (renda, profissão, estado civil, tempo de emprego) consegue prever quem vai atrasar?
2. Que informações mais ajudam a prever?
3. Como transformar a previsão em uma regra prática de aprovação?

Os dados utilizados

O trabalho usou duas bases fornecidas no desafio. Elas se ligam pelo número da conta.

Base	O que contém	Tamanho
Ficha cadastral	renda, profissão, estado civil, escolaridade, moradia, idade, tempo de emprego, filhos	438.557 pedidos
Histórico de pagamento	situação de cada conta mês a mês: em dia, quitada ou com atraso (e de quantos dias)	45.985 contas, até 61 meses cada

Três pontos de atenção sobre esses dados:

- **Só 8% dos pedidos têm histórico de pagamento.** Sem histórico não dá para saber se a pessoa pagou ou não, então o estudo se baseia em 36.457 contas.
- **A mesma pessoa aparece várias vezes.** Essas contas pertencem a cerca de 9.700 pessoas, com 3,7 contas por pessoa em média. Isso exigiu cuidado na hora de testar o modelo (veja "Como o modelo foi construído").
- **Há falhas de cadastro.** A profissão está em branco em 31% das fichas, o tempo de emprego dos aposentados vem com um código no lugar do valor e 47 contas aparecem duplicadas com fichas diferentes. Todos esses casos foram tratados antes da análise.

O que chamamos de mau pagador

Mau pagador é a conta que atrasou 60 dias ou mais em algum dos seus 12 primeiros meses. As bases não traçam essa linha; ela foi definida a partir do comportamento real das contas.

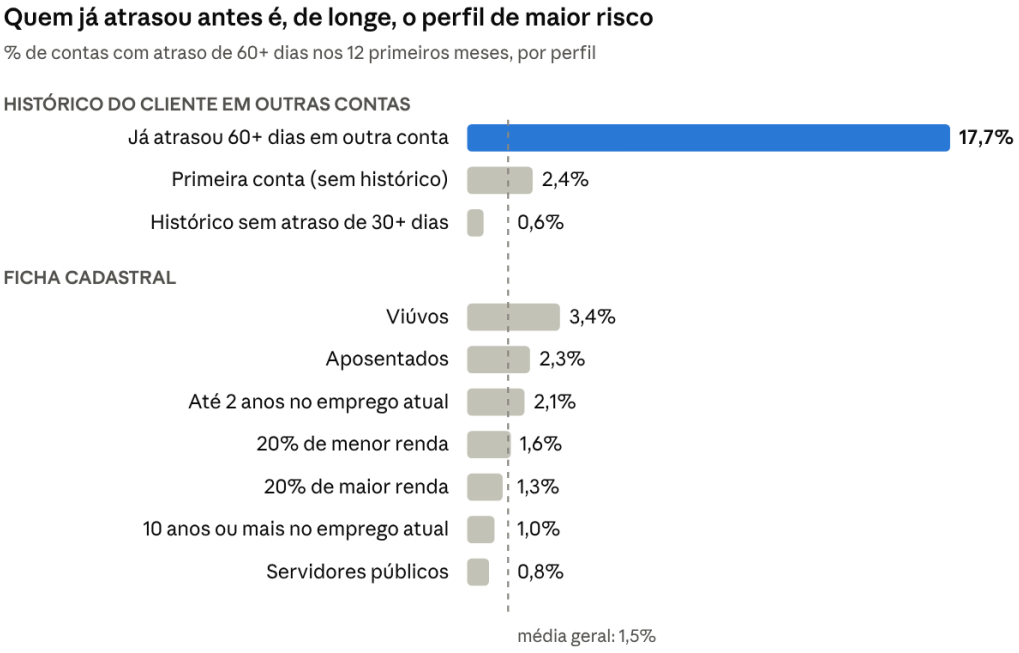
- **Por que 60 dias.** Atrasos de 30 a 59 dias quase sempre se resolvem: 86% dessas contas voltam a ficar em dia. A partir de 60 dias o quadro muda, e metade das contas continua piorando. É a partir daí que o atraso vira risco real de prejuízo.
- **Por que os 12 primeiros meses.** Uma conta observada por cinco anos teve muito mais tempo para atrasar do que uma aberta há seis meses. Olhar todas no mesmo período de vida torna a

comparação justa. Em 12 meses já aparecem cerca de 60% dos atrasos graves que surgiriam em três anos.

Com essa regra, entram no estudo 24.566 contas de 7.946 clientes. **Apenas 370 são de maus pagadores: 1,5%, ou 1 a cada 66 contas.** Por ser um evento raro, "acertar 98% das vezes" não significa nada: aprovar todo mundo já acertaria 98,5% e não barraria nenhum calote. Por isso os resultados deste relatório são medidos pela capacidade de encontrar os maus pagadores, e não pela taxa geral de acertos.

O que os dados revelaram

O comportamento passado do cliente diz muito mais sobre o risco do que a ficha cadastral. Quem já atrasou mais de 60 dias em outra conta tem taxa de calote 12 vezes maior que a média. Na ficha, as diferenças entre perfis são pequenas.



análise exploratória (notebook 01) · 24.566 contas com 12 meses de histórico

Três leituras para o negócio:

- **Renda não separa bons de maus pagadores nesta base.** Os 20% que ganham mais atrasam quase na mesma proporção que os 20% que ganham menos. Regras do tipo "só aprovar acima de tal renda" não encontram apoio nos dados.
- **Estabilidade ajuda um pouco.** O risco cai de forma contínua com o tempo no emprego atual. Servidores públicos e casados ficam abaixo da média; viúvos, solteiros e aposentados, acima.
- **Cliente novo é um ponto cego.** Quem pede a primeira conta tem risco acima da média (2,4%), e sobre ele o banco só conhece a ficha.

Como os dados foram preparados

Antes de treinar qualquer modelo, os dados foram limpos e enriquecidos. Os principais passos foram:

Situação encontrada	O que foi feito
Profissão em branco (31% das fichas)	separada em "aposentado sem vínculo" e "não informada", sem inventar uma profissão
Código no lugar do tempo de emprego dos aposentados	trocado por um indicador "sem vínculo de emprego"
Idade e tempo de emprego contados em dias	convertidos em anos
Casos extremos (até 19 filhos, famílias de 20 pessoas)	limitados a 3 filhos e 5 pessoas
47 contas duplicadas com fichas diferentes	removidas
Campo "possui celular" igual para todos	descartado, pois não diferencia ninguém

Também criamos novas informações a partir das existentes:

- **Renda por pessoa da família**, porque a mesma renda sustenta uma pessoa ou cinco.
- **Estabilidade no emprego**, isto é, a parte da vida adulta passada no emprego atual.
- **Histórico anterior do cliente.** Para cada pedido, verificamos como a mesma pessoa se comportou em outras contas, usando somente os meses anteriores ao pedido. É exatamente a informação que o banco teria em mãos no dia da solicitação. Em 66% dos pedidos esse histórico existe.

Como o modelo foi construído

O modelo aprendeu com 80% dos clientes e foi avaliado nos outros 20%, que ele nunca tinha visto. É como uma prova com questões inéditas: só assim o resultado mostra o que vai acontecer com clientes novos.

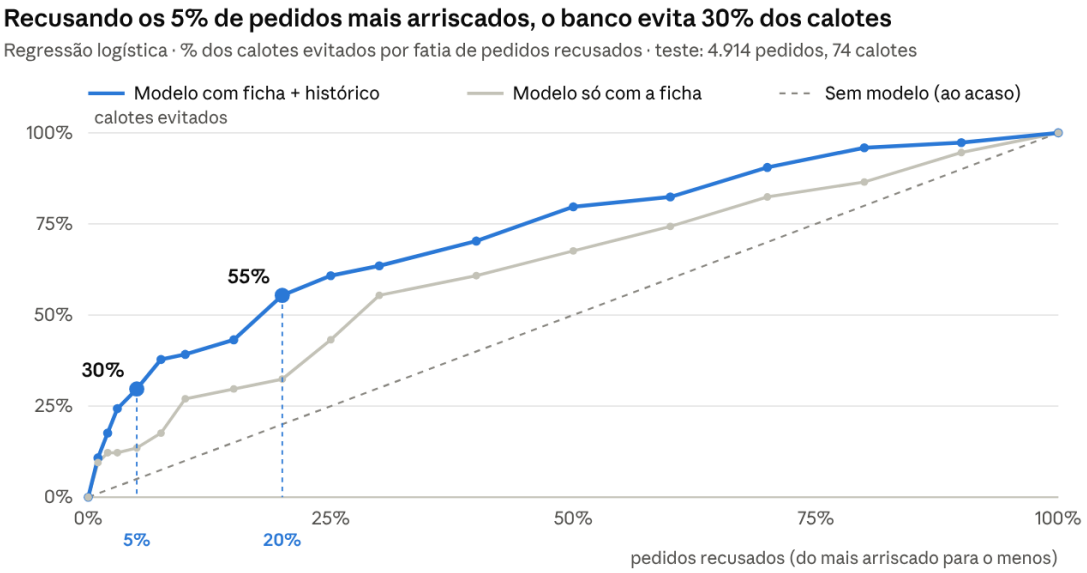


processo de construção e teste do modelo · notebooks 03 e 04

- **Clientes separados, não contas.** Como a mesma pessoa tem várias contas com a mesma ficha, separar por conta deixaria a pessoa dos dois lados. O modelo "decoraria" a ficha e pareceria melhor do que é. Medimos esse efeito: misturando, o modelo só com a ficha parecia acertar 76% a 82%; separando corretamente, acerta 60%.
- **Cinco tipos de modelo comparados**, de regras simples a combinações de centenas de árvores de decisão, cada um com e sem o histórico do cliente.
- **Os calotes são raros (1,5%)**, então cada calote recebeu mais peso no treino. Sem isso, o modelo aprenderia que "aprovar todo mundo" quase sempre acerta.
- **Empate decidido pela explicabilidade.** Nas 15 rodadas de teste internas, os três melhores modelos ficaram dentro da variação normal entre rodadas. A regra de escolha usa apenas essas rodadas internas: havendo empate, fica o modelo mais simples. O escolhido foi a **regressão logística**, que dá um peso a cada fator e permite explicar cada decisão ao cliente e ao regulador.

Resultados

Na prova final, com clientes que o modelo nunca viu, recusar os 5% de pedidos mais arriscados evitaria 30% dos calotes. Recusar 20% evitaria 55%. Sem o histórico do cliente, o mesmo corte de 5% evitaria apenas 14%.



conjunto de teste (notebook 04) · 4.914 pedidos de 1.576 clientes nunca vistos pelo modelo

Cada corte tem um custo: bons clientes recusados junto com os maus. A tabela resume o que se ganha e o que se perde em cada opção.

Recusando os pedidos mais arriscados	Calote entre os aprovados	Bons clientes recusados para cada calote evitado
nenhum (sem modelo)	1,51%	—
2%	1,27%	7

Recusando os pedidos mais arriscados	Calote entre os aprovados	Bons clientes recusados para cada calote evitado
5%	1,11%	10
10%	1,02%	16
20%	0,84%	23

Como ler: recusar os 5% mais arriscados derruba o calote entre os aprovados de 1,51% para 1,11%. Em troca, são recusados 10 bons clientes para cada calote evitado. O modelo acerta mais nos extremos: na metade mais segura dos pedidos, o calote é de 0,61%; entre os 5% mais arriscados, de 8,9%.

Por que a regressão logística. Testamos cinco tipos de modelo, e os três melhores ficaram praticamente empatados, com acerto entre 71% e 73% na prova final. O *Random Forest* teve nota um pouco maior nas rodadas internas e a regressão logística, na prova final, mas as duas diferenças cabem na margem de erro. No resultado de negócio os dois são iguais: ambos evitam os mesmos 30% dos calotes no corte de 5%. Diante do empate, escolhemos a regressão logística por ser explicável: cada recusa pode ser justificada pelos fatores e seus pesos, o que conta para o cliente, para a auditoria e para o regulador. A diferença de verdade não está no algoritmo, e sim no histórico do cliente: sem ele, o melhor modelo cai para 63%.

O que mais pesa na decisão

Cinco das seis informações mais importantes para o modelo vêm do histórico do cliente; renda, escolaridade e profissão não pesam. O peso foi medido retirando uma informação de cada vez e observando quanto o modelo piora.



importância por permutação, medida fora da amostra de treino (notebook 04)

- **Os dois fatores principais são o tempo de relacionamento e o pior atraso já registrado.** Um cliente com muitos meses de histórico e várias contas é alguém a quem o banco já concedeu crédito repetidas vezes sem problema. Já quem atrasou mais de 60 dias tende a repetir o comportamento.
- **Cada fator tem um peso com direção clara.** Aumentam o risco: atraso anterior grave, meses com atraso de 30+ dias, ser aposentado ou viúvo. Reduzem o risco: tempo de relacionamento, número de contas anteriores, ser casado ou servidor público, tempo no emprego atual. É isso que permite justificar cada recusa.
- **Da ficha, só estabilidade conta um pouco:** tempo de emprego, tipo de renda, moradia e estado civil. Gênero aparece na lista, mas retirá-lo, junto com idade e estado civil, praticamente não muda o desempenho (de 75,4% para 75,3% nas rodadas internas).

O Random Forest, um modelo de outra família, chegou às mesmas conclusões. Isso dá confiança de que o resultado reflete os dados, e não uma peculiaridade do algoritmo escolhido.

Recomendações para o negócio

1. **Colocar o histórico interno do cliente no centro da análise.** É a informação que mais separa bons e maus pagadores. Ela deve estar sempre à mão de quem decide, com ou sem modelo.
2. **Usar o modelo em três faixas, e não como um "sim ou não" automático:**
    - metade mais segura dos pedidos: aprovação automática;

    - faixa intermediária: aprovação com limite inicial mais baixo, que cresce conforme o cliente paga em dia;
    - 5% mais arriscados: análise manual ou recusa.
3. **Definir o ponto de corte com números financeiros.** Recusar os 5% mais arriscados significa recusar cerca de 10 bons clientes para cada calote evitado. Isso compensa se o prejuízo médio de um calote for maior que o lucro de 10 bons clientes. A área de crédito tem esses valores; o projeto não tinha.
4. **Buscar informação externa para clientes novos.** Quem pede o primeiro cartão tem mais risco e é onde o modelo menos enxerga. Bureau de crédito, cadastro positivo e open finance tendem a ajudar mais do que algoritmos mais sofisticados.
5. **Retirar gênero, idade e estado civil do modelo.** O teste mostrou que o desempenho praticamente não muda sem essas informações. Retirá-las reduz o risco regulatório e de imagem sem custo.

Limitações e próximos passos

O que o modelo não faz

- **Não identifica cada mau pagador.** No ponto de corte usado nos testes, 8 em cada 10 maus pagadores ainda seriam aprovados. O modelo reduz o calote, mas não o elimina.
- **Trabalha com poucos casos de calote.** São 370 na base inteira e 74 no teste, o que deixa uma margem de erro larga nos resultados.
- **É mais fraco com clientes novos**, justamente o público de maior risco.
- **A nota que ele dá é uma ordem de risco, não uma probabilidade.** Uma nota de 0,6 não significa 60% de chance de calote. Para usar a nota em preço ou provisão, ela precisaria ser ajustada.

Limites dos dados

- Não há identificador de pessoa (como CPF). Consideramos que fichas idênticas em todos os campos são da mesma pessoa.
- O histórico cobre cinco anos e o arquivo parece ter sido cortado na origem: ele tem exatamente o número máximo de linhas de uma planilha do Excel.
- Só há resultado para quem recebeu o cartão. Não sabemos como os recusados teriam se comportado.
- Não há valores em reais (limite, saldo, valor em atraso), então não foi possível calcular o prejuízo evitado em dinheiro.

Próximos passos sugeridos

1. Incluir dados de bureau de crédito e de movimentação bancária.
2. Testar o modelo em contas abertas depois do período de treino, simulando o uso real.
3. Definir o ponto de corte em reais, com prejuízo e margem reais.
4. Verificar se as taxas de aprovação e de erro são justas entre gêneros e faixas etárias.
5. Acompanhar o desempenho do modelo depois da implantação.

Entregáveis técnicos

Todo o trabalho está no repositório do projeto e pode ser refeito do zero com os mesmos resultados.

Item	Conteúdo
`notebooks/01_eda.ipynb`	análise exploratória dos dados, com gráficos comentados
`notebooks/02_preprocessamento.ipynb`	limpeza, definição de mau pagador e criação das novas informações
`notebooks/03_modelagem.ipynb`	treino e comparação dos modelos
`notebooks/04_avaliacao.ipynb`	resultados no teste, fatores de decisão e conclusões
`run_pipeline.py`	refaz tudo por linha de comando, dos arquivos brutos aos resultados
`results/`	gráficos e tabelas de resultados

Ferramentas: Python, pandas e scikit-learn.